

LLM 에이전트의 세계모델로서 타입화된 판단: JEV 방식과 생성형 방식의 비교

Typed Judgments as World Models for LLM Agents: Comparing the JEV Style with Generative World Models

(저자명)¹
(Author Name)

¹(소속 기관 학과)
E-mail: (이메일)

요약

본 논문은 LLM 에이전트의 세계모델로서 선택지 확률을 반환하는 타입화된 판단 방식(JEV 방식)과 다음 상태를 사실 목록으로 생성하는 방식을 같은 재귀 rollout 과 계획기에서 비교한다. TextWorld 과제에서 기본 에이전트의 성공률은 17.0%, 실패 기억만 쓴 에이전트는 79.5%였고, frozen JEV 는 93.4%, 환경 전이 6,000 개로 학습한 LLM 은 두 방식 모두 92.7%였다. 학습 없는 LLM 에서는 타입화(83.0%)가 생성형(59.0%)보다 높았으나, 이 차이는 생성형이 한 step 예측의 26.0%를 과성할 수 없는 형식으로 낸 데서 비롯됐고 학습 뒤 사라졌다. 학습한 LLM 의 다단계 예측은 학습한 구조에서 JEV 보다 정확했지만, 새 구조에서는 정확도가 JEV 보다 25.6%p(타입화), 26.7%p(생성형) 더 떨어졌다.

키워드: 세계모델(World Model), LLM 에이전트(LLM Agent), 타입화된 판단 모델(Typed Judgment Model), 생성형 세계모델(Generative World Model), TextWorld

1. 서론

LLM 에이전트는 행동의 결과를 모른 채 행동을 골라 무효하거나 목표와 무관한 행동을 반복한다. 행동의 결과를 미리 상상하는 세계모델(world model)로 후보 행동을 평가하면 이를 줄일 수 있고, 보통 LLM 이 다음 상태를 문장으로 생성한다 [1]. 그러나 그 예측은 부정확하다고 알려져 있다 [2].

JEV [3]는 상태와 질문을 받아 연구자가 정한 선택지 위의 확률을 반환하는 타입화된 판단 모델(typed judgment model)이다. 이 방식에서는 다음 상태를 쓰게 하는 대신 "이 행동 뒤 열쇠는 어디에 있는가"를 선택지로 묻는다. 본 논문은 이 방식이 세계모델로서 생성형보다 나은지, 그 이점을 JEV 없이 학습한 LLM 으로도 얻을 수 있는지를 묻는다. 이를 위해 두 방식을 같은 재귀 rollout 과 계획기에 연결하고, frozen JEV 와 학습 전후의 LLM 으로 2×2 비교를 구성해 과제 성공률과 다단계 예측을 평가한다.

2. 방법

2.1 과제와 공통 계획기

환경은 완전관측 TextWorld [4]다. 매 step 정책(Qwen3-4B [5])이 길이 2 의 후보 행동열을 제안하고(8 개씩 두 번 샘플링), 계획기는 세계모델로 각 후보의 결과를 상상해 식 (1)의 효용이 가장 큰 후보의 첫 행동만 실행한 뒤 실제 관측에서 다시 계획한다.

$$J(u) = P(G|s, u) + \alpha \cdot \text{prog}(s, u) - \lambda \cdot E[N_{\text{inv}}(u)] - c|u| + \beta \cdot b_{\pi}(u) \quad (1)$$

G 는 목표 조건의 동시 충족, prog 는 충족된 조건의 비율, N_{inv} 는 실행되지 않을 명령 수, b_{π} 는 정책 순위에서 얻은 사전값이고, $\alpha=0.25$, $\lambda=0.1$, $c=0.01$, $\beta=0.05$ 다.

계획하는 에이전트는 모두 현재 상태에서 이미 실패한 명령으로 시작하는 후보를 제외하고(실패 기억), 모든 후보가 그런 명령으로 시작하면 정책에 한 번 다시 묻는다.

2.2 세계모델: 한 걸음 예측의 반복

세계모델은 (상태, 행동)에서 다음 상태를 예측하고, 그 예측을 다시 입력해 여러 step 을 상상한다. 전이 규칙은 주지 않는다. 타입화 방식은 명령의 실행 여부와 실행 뒤 각 상태 변수(위치, 물체의 소재, 문과 용기의 상태)의 값을 선택지로 묻고 확률을 받으며, 실행 확률로 "실행"과 "실패"를 가중해 폭 4 의 beam 으로 굴린다. 생성형 방식은 실행 여부와 다음 상태의 사실 목록을 쓰게 하고 과서로 같은 상태 형식으로 바꾼다. 과성할 수 없는 응답(한 변수의 값이 둘이거나 없음)은 한 번 다시 생성하고, 그래도 실패하면 "실행 안 됨"으로 처리한다.

2.3 비교하는 에이전트

C 는 세계모델 없이 정책의 1 순위 계획을 따르고, C_{fm} 은 C 에 실패 기억만 더한다. 타입화 세계모델은 frozen JEV(A), 학습 없는 Qwen3-4B(B0), LoRA [6]로 학습한 Qwen3-4B(B)이고, 생성형은 학습 없는 Qwen3-4B(D0)와 학습한 Qwen3-4B(D)다. B 와 D 는 같은 환경 전이 6,000 개로 학습하고 정답의 형식만 다르다. Qwen 은 선택지 글자의 다음 토큰 확률을 선택지 확률로 쓴다. 참조선인 validity 는 실행 여부만, oracle 은 다음 상태까지 환경의 정답을 쓴다. oracle 은 같은 후보와 효용에 완벽한 예측을 넣은 진단 기준이며 성능 상한이 아니다.

3. 실험

3.1 설정

과제는 방 두 개, 열쇠가 든 상자, 탁자 위의 목표 음식, 잠긴 문, 미끼 음식으로 이루어지고, 목표는 목표 음식을

들고 문을 연 채 먼 방에 있는 것이다. 평가 world 24 개는 학습과 보정에 쓰지 않은 단어로 이름을 지었으나 구조는 학습과 같다(평가 전이의 69.5%는 이름만 다른 전이가 학습 데이터에 있다). 시작 상태 4 개와 정책 seed 3 개로 에이전트당 288 episode 를 최대 30 step 실행하고, world 단위 bootstrap 95% 신뢰구간을 보고한다. 정책 설정은 별도의 world 에서 세계모델 없는 기준선의 성공률로 정했다. 앞선 두 설계는 모든 세계모델이 oracle 과 같은 58.7%에 머물거나 보정이 평가 world 로 옮겨지지 않아 다시 설계했다.

3.2 과제 성공률

표 1 에서 C 는 17.0%, C_{fm} 은 79.5%였고, 세계모델을 쓴 A 와 B·D 는 C_{fm} 보다 각각 13.9%p [2.1, 24.3], 13.2%p [2.8, 22.9] 높았다. 실패 기억만 있는 에이전트와 비교해도 세계모델의 이득이 남았다. B 와 D 는 모든 episode 에서 oracle 과 성공 여부가 같았고 A 와 oracle 의 차이는 구분되지 않아, 이 과제의 성공률은 세 세계모델을 가르지 못한다.

표 1. 세계모델별 과제 성공률과 비용.

Table 1. Task success and cost by world model.

Agent	Success (%)	Inv. (%)	WM cost / ep.
C	17.0 [7.3, 29.2]	87.8	–
C_{fm}	79.5 [70.5, 87.5]	35.0	–
A (JEV)	93.4 [85.1, 98.6]	15.4	129 req., \$0.010
B0	83.0 [73.3, 91.3]	48.6	49 GPU-s
D0	59.0 [48.6, 69.1]	36.3	115 GPU-s
B	92.7 [85.8, 97.9]	13.2	42 GPU-s
D	92.7 [85.8, 97.9]	13.2	73 GPU-s
Validity	85.8 [77.8, 92.7]	10.8	–
Oracle	92.7 [85.8, 97.9]	12.8	–

Brackets: 95% CI. B, D: 6,000 training transitions (13.9, 4.5 GPU-h).

학습 없는 LLM 에서는 타입화 B0 가 생성형 D0 보다 24.0%p [11.5, 35.8] 높았고, D0 는 C_{fm} 보다도 20.5%p 낮았다. 원인은 출력 형식이다. D0 는 한 step 예측의 26.0%에서 한 물체를 두 곳에 두는 등 파싱할 수 없는 상태를 냈고, 이것이 "실행 안 됨"으로 처리되어 에이전트가 음식 집기를 피하다가 음식 없이 먼 방에 들어가(D0 40%, C_{fm} 21%) 대부분 회복하지 못했다. 파싱된 응답만 보면 D0 의 한 step 정확도는 B0 보다 낮지 않았다. 학습 뒤에는 파싱 실패가 0.1%로 줄고 B 와 D 의 차이도 사라졌다. 즉 타입화의 이점은 학습 데이터가 없을 때의 형식 견고성이다. A 와 B0 의 차이(+ 10.4%p)는 이 표본으로는 구분되지 않았다.

3.3 다단계 예측

그림 1 은 시작 상태 400 개에서 길이 4 의 행동열 두 종류(정책, 무작위)를 굴린 rollout 800 개의 상태 완전일치다. 평가 world 에서 학습한 B 와 D 는 4 step 뒤에도 98.5%, 96.8%였고, A 는 90.9%에서 77.9%로 떨어졌다. 학습 없는 Qwen 은 아무것도 바뀌지 않는다고 예측하는 기준(persistence) 수준이거나 그보다 낮았다. 그러나 결방, 미끼 열쇠, 둘째 용기를 더한 새 구조에서는 B 와 D 의 정확도 하락이 A 보다 25.6%p [18.8, 33.9], 26.7%p [21.7, 31.6] 컸다. 학습의 이득은 학습한 구조

안에 머물렀다. 자기 예측을 이어 굴릴 때의 오류 누적은 두 방식 사이에 구분되지 않았다.




그림 1. rollout 길이에 따른 상태 예측 정확도.

Fig. 1. State prediction accuracy vs. rollout length.

4. 결론

세계모델은 실패 기억만 쓴 에이전트보다 성공률을 높였고, frozen JEV 는 과제 학습 없이도 완벽한 예측을 넣은 기준과 구분되지 않았다. 타입화의 이점은 학습 전의 형식 견고성이었고 학습 뒤 사라졌으며, 학습한 LLM 은 학습한 구조에서는 더 정확했지만 새 구조에서는 JEV 보다 크게 떨어졌다. 한계는 완전관측 TextWorld 의 한 과제 구조, 두 step 계획, 한 가지 LLM, 연구자가 설계한 상태 변수와 파싱 실패 처리 규칙, 응답이 실행마다 달라질 수 있는 외부 API 다. 향후 다른 환경과 새 구조에서의 과제 성공률로 확장한다.

참 고 문 헌

- [1] S. Hao et al., "Reasoning with Language Model is Planning with World Model," *Proc. EMNLP*, pp. 8154–8173, 2023.
- [2] R. Wang et al., "Can Language Models Serve as Text-Based World Simulators?," *Proc. ACL*, pp. 1–17, 2024.
- [3] TypeSafe AI, "Introducing System One Models & Jev," Available: <https://typesafe.ai/blog/introducing-system-one-models-and-jev>, [Accessed: Sep. 30, 2026].
- [4] M.-A. Côté et al., "TextWorld: A Learning Environment for Text-based Games," *Proc. IJCAI Computer Games Workshop*, 2018.
- [5] A. Yang et al., "Qwen3 Technical Report," arXiv:2505.09388, 2025.
- [6] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models," *Proc. ICLR*, 2022.